의료 데이터 반출 제한 환경에서의 연합 평가 및 합성 데이터 기반 의료 AI 평가 프레임워크

02 MBP
김채영, 정지현

1. Team Info

1.1. 과제(논문)명

- 의료 데이터 반출 제한 환경에서의 연합 평가 및 합성 데이터 기반 의료 AI 평가 프레임워크
- A Medical AI Evaluation Framework Based on Federated Evaluation and Synthetic Data under Medical Data Transfer Restrictions

1.2. 팀 정보

- 02
- MBP
- 연구트랙

1.3. 팀 구성원

- 김채영(2271021) : 리더, 프로젝트 기획, 평가 파이프라인 설계, 시스템 구조 설계
- 정지현(2371055) : 데이터 전처리 및 실험 설계, 프록지 평가 구조 구현

2. Project-Summary

2.1. 문제 정의

2.1.1 연구의 배경 및 필요성

최근 의료 인공지능(AI)은 질환 예측, 영상 판독, 임상 의사결정 지원 등 다양한 영역에서 활용 가능성을 확대하고 있다. 그러나 의료 AI 모델이 실제 임상 현장에서 활용되기 위해서는 특정 데이터셋에서 높은 성능을 보이는 것만으로는 충분하지 않다. 의료기관마다 환자 구성, 질환 분포, 검사 장비, 촬영 조건, 데이터 품질, 판독 기준 등이 서로 다르기 때문에, 한 기관이나 공개 데이터셋에서 우수한 결과를 보인 모델이라 하더라도 다른 기관 환경에서 동일한 수준의 성능과 신뢰성을 유지한다고 보기 어렵다. 따라서 의료 AI의 실질적인 활용 가능성을 판단하기 위해서는 다양한 기관 환경에서의 일반화 성능과 안정성을 검증할 수 있는 평가 체계가 필요하다.

실제 의료 데이터는 개인정보 보호, 병원 보안 규정, 법적 제한 등으로 인해 외부 반출이 어려워, 여러 기관의 원본 데이터를 통합해 평가하는 방식은 현실적으로 제약이 크다. 그 결과로 의료 AI 평가는 공개 데이터셋이나 단일 기관 데이터에 의존하는 경우가 많다. 이는 실제 의료 환경의 다양성과 기관 간 데이터 이질성을 충분히 반영하지 못하며, 다기관 환경에서 발생할 수 있는 성능 저하나 일반화 한계를 사전에 확인하기 어렵다는 문제를 가진다. 또한 의료기관에서는 테스트 데이터 자체가 부족한 경우가 많고, 특히 희귀 사례나 경계 사례는 충분히 확보하기 어려워 모델의 취약성과 강건성을 폭넓게 평가하기 어렵다. 따라서 의료 데이터 반출 제한이라는 현실적 제약을 전제로 하면서도, 다기관 환경과 데이터 부족 문제를 함께 고려할 수 있는 새로운 의료 AI 평가 방법론이 필요하다.

2.2.2 연구 목적

연구의 목적은 의료 데이터 반출이 제한된 환경에서 원본 환자 데이터를 외부로 공유하지 않고도 의료 AI 모델의 성능을 평가할 수 있는 방법론적 프레임워크를 제안하는 것이다.
이를 위해 각 의료기관은 자체 보유한 원본 데이터를 기관 내부의 보안 환경에서만 사용하여 동일한 평가 절차를 수행하고, 동시에 원본 데이터로부터 추출한 특징 표현 또는 통계치를 기반으로 합성 데이터를 생성한다. 이후 기관 외부에서는 이 합성 데이터를 이용해 프록시 평가를 수행하고, 내부 real evaluation 결과와 외부 proxy evaluation 결과를 비교·분석함으로써, 프록시 데이터가 원본 데이터를 대체하는 평가 수단으로서 어느 정도의 충실도와 타당성을 가지는지를 검증하고자 한다. 즉, 합성 데이터의 임상적 정확도를 직접 입증하는 것이 아니라, 프록시 데이터가 실제 평가를 얼마나 잘 근사하는 평가 대체물로 기능할 수 있는지를 확인하는 데 초점을 둔다.

2.2. 기존 연구와의 비교

2.2.1 MedPerf [1]

MedPerf는 의료 AI 모델을 다양한 기관의 데이터로 평가하기 위해, 데이터를 외부로 공유하지 않고 모델을 데이터가 있는 기관으로 보내어 성능을 검증하는 federated evaluation(연합 평가) 플랫폼을 제안한 연구이다. 논문은 의료 AI의 실제 적용을 위해서는 대규모·다기관 데이터에 대한 일반화 성능 검증이 필요하지만, 개인정보 보호, 규제, 비용 등의 문제로 데이터 공유가 어렵다는 점을 문제로 제시한다. 이를 해결하기 위해 MedPerf는 데이터 대신 모델을 각 기관으로 배포하고, 각 기관은 로컬 환경에서 모델을 실행한 뒤 성능 지표만 중앙으로 제출하는 구조를 채택하였다. 즉, 원본 데이터를 외부로 반출하지 않으면서도 다기관 환경에서 모델 성능을 검증할 수 있도록 한 플랫폼 중심의 접근이다. 또한 평가 결과는 집계된 metric 중심으로 관리되며, 실제로 여러 기관과 파일럿 스터디를 통해 플랫폼의 확장성과 실사용 가능성을 검증하였다.

본 연구 역시 원본 의료데이터를 외부로 반출하지 않고 병원 내부에서 평가를 수행한다는 점에서 MedPerf와 유사하다. 그러나 MedPerf는 기존 모델을 각 기관 데이터로 평가하는 federated benchmarking platform에 초점을 둔 반면, 본 연구는 병원 내부 실제 평가 결과를 외부의 proxy 평가로 어느 정도 근사할 수 있는지 검증하는 privacy-preserving benchmark method를 제안한다는 점에서 차이가 있다. 즉, MedPerf는 “모델을 데이터가 있는 곳으로 보내 평가한다”는 평가 인프라 자체에 집중하고, 본 연구는 “원본을 공유하지 않고도 외부에서 대체 평가가 가능한가”라는 방법론에 집중한다.

2.2.2 SF(DA)² [2]

SF(DA)²는 source-free domain adaptation 상황에서, 원본 source domain 데이터를 사용하지 않고도 새로운 target domain에 모델을 적응시키기 위한 방법을 제안한 연구이다. 이 논문은 기존 SFDA 기법들이 데이터 증강을 활용할 때 class-preserving transformation에 대한 사전지식이 필요하고, 증강 샘플 수가 많아질수록 연산량과 메모리 사용량이 증가한다는 한계를 지적한다. 이를 해결하기 위해 pretrained model의 feature space에서 target feature 간 이웃 관계를 이용해 augmentation graph를 구성하고, spectral neighborhood clustering, implicit feature augmentation, feature disentanglement를 통해 명시적 증강 없이도 target domain adaptation 성능을 높이는 방법을 제안하였다. 즉, 핵심 목적은 원본 source 데이터 없이 target domain에 모델을 더 잘 적응시키는 것이며, feature space와 통계적 구조를 활용한다는 점이 특징이다.

본 연구는 SF(DA)²와 마찬가지로 데이터를 직접 공유하지 않고 feature-level 정보나 통계적 정보를 활용한다는 유사성이 있다. 특히 두 연구 모두 병원 내부에서 원본 데이터를 모델에

---

[1] Alexandros Karargyris et al., “Federated benchmarking of medical artificial intelligence with MedPerf,” *Nature Machine Intelligence*, vol. 5, no. 7, pp. 799–810, 2023.
[2] Hwang et al., “SF(DA)²: Source-free Domain Adaptation Through the Lens of Data Augmentation,” *ICLR 2024*.

넣어 feature vector 또는 그 통계치를 추출하고, 병원 외부에서는 이를 바탕으로 proxy 데이터를 구성하고, feature space를 활용해 원본 데이터 없이 다른 목적의 연산을 수행한다는 점이 공통적이다. 그러나 SF(DA)²는 도메인 차이를 줄여 target domain에서의 모델 성능을 향상시키는 adaptation 연구이고, 본 연구는 병원 내부 실제 평가 결과를 외부 proxy 평가로 얼마나 잘 근사할 수 있는지 검증하는 benchmark 연구이다. 따라서 SF(DA)²의 feature augmentation은 adaptation 성능 개선을 위한 것이지만, FedSyn-MedBench에서의 synthetic/proxy 구성은 학습용 데이터 증강이 아니라 외부 평가를 위한 대체 evaluation set 구성이라는 점에서 사용 목적이 다르다.

2.2.3 Real-world prediction of preclinical Alzheimer's disease with a deep generative model [3]

해당 연구는 알츠하이머병의 초기 지표인 amyloid positivity를 직접적으로 검사하는 대신, structural MRI, 인구통계 변수, 인지검사 점수와 같은 proxy measure를 활용하여 예측하는 deep generative model을 제안한 논문이다. 논문은 실제 임상 데이터가 missing feature, missing label, class imbalance와 같은 불완전성(imperfect dataset)을 자주 포함한다는 점을 문제로 제시하고, 이를 해결하기 위해 HexaGAN 기반의 생성모델 구조를 확장하여 고차원 영상 데이터와 표 형식 임상 데이터를 함께 처리하는 방식을 제안하였다. 또한 학습 데이터와 실제 적용 데이터의 feature set이나 진단 기준이 다르더라도 모델이 적응적으로 작동할 수 있음을 강조하며, 서로 다른 병원 환경에서도 활용 가능한 real-world clinical translation 가능성을 보여주었다. 즉, 직접 측정이 어렵거나 비용 부담이 큰 임상 대상을 proxy measure로 대체하여 예측하고, missing feature, missing label, class imbalance가 존재하는 실제 의료데이터 환경에서도 활용 가능하도록 generative model을 설계한 연구이다.

본 연구는 해당 논문과 마찬가지로 원본 의료데이터를 직접 외부에 공유하지 않고, 대체 가능한 표현 또는 proxy 정보를 활용한다는 점에서 유사성이 있다. 특히 두 연구 모두 의료데이터가 원본 그대로 주어지지 않는다는 현실을 전제로 하며, 다른 형태의 정보를 활용해 실제 임상 환경에서 적용 가능한 방법을 모색한다는 공통점이 있다. 그러나 Alzheimer generative model 연구는 직접 측정이 어려운 임상 target을 proxy measure로 예측하는 진단 모델 연구인 반면, 본 연구는 병원 내부 실제 평가 결과를 병원 외부의 proxy 평가가 얼마나 잘 근사할 수 있는지 검증하는 benchmark method 연구라는 점에서 차이가 있다. 다시 말해, 해당 연구가 "proxy measure를 활용해 질환 여부를 예측하는 것"에 초점을 둔다면, 본 연구는 "원본 데이터를 공유하지 않고도 외부에서 대체 평가가 가능한가"를 다룬다. 따라서 이 연구는 본 연구의 직접적인 구조적 선행연구라기보다는, proxy 개념의

[3] Hwang et al., "Real-world prediction of preclinical Alzheimer's disease with a deep generative model," *Artificial Intelligence in Medicine*, vol. 144, article 102654, 2023.

의료 적용 가능성과 불완전한 의료데이터 환경에서의 generative modeling 활용 가능성을 보여주는 참고 연구로 위치지을 수 있다.

2.3. 제안 내용

의료 AI는 다양한 환경에서 실제로 사용되기 전에 충분한 성능 검증이 필요하지만, 의료데이터는 개인정보 보호와 규제 문제로 인해 외부 반출이 어렵기 때문에 병원별 실제 환경을 반영한 평가를 수행하기가 쉽지 않다. 이로 인해 대형 데이터셋에서 높은 성능을 보인 모델이라 하더라도, 새로운 병원 환경에서도 동일하게 신뢰할 수 있는지 검증하기 어렵다는 문제가 발생한다.

본 연구는 이러한 한계를 해결하기 위해, 원본 의료데이터를 외부로 공유하지 않으면서도 평가가 가능하도록 병원 내부 실제 평가와 병원 외부 proxy 평가를 결합한 privacy-preserving benchmark method를 제안한다. 구체적으로 병원 내부에서는 원본 ECG, X-ray 데이터를 이용해 실제 성능을 평가하고[4], 동시에 feature vector 또는 그 통계치를 추출한다. 이후 병원 외부에서는 이 비식별 중간 표현을 바탕으로 proxy evaluation set을 구성하여 동일한 모델의 성능을 다시 산출하고, 이를 병원 내부 실제 평가 결과와 비교함으로써 외부 평가가 실제 평가를 어느 정도 근사할 수 있는지를 검증한다.

즉, 본 연구의 해결책은 원본 데이터 반출 없이도 의료 AI의 성능을 검증할 수 있는 대체 평가 체계를 설계하고, 이를 통해 데이터 공유 제약이 큰 의료 환경에서도 활용 가능한 benchmark method를 구축하는 데 있다.

2.4. 기대 효과 및 의의

병원 원본 데이터를 외부로 반출하지 않고도 의료 AI 모델을 평가할 수 있는 privacy-preserving benchmark method를 제안한다는 점에서 의의가 있다. 실제 의료 현장에서는 개인정보 보호와 데이터 반출 제한으로 인해 병원 데이터를 직접 활용해 모델 성능을 검증하기 어렵다. 본 과제는 이러한 한계를 해결하기 위해, 병원 내부에서는 원본 ECG·X-ray 데이터로 실제 평가를 수행하고, 외부에서는 원본 대신 모델의 feature vector 또는 그 통계치만을 활용해 proxy 평가를 수행한 뒤, 두 결과의 유사성을 검증하는 구조를 설계하였다. 즉, 데이터 공유가 어려운 환경에서도 원본 성능을 근사할 수 있는 평가 방법론 자체를 제안한다는 점에서 기존의 단순 데이터셋 구축이나 모델 개발 중심 접근과 차별화된다.

연구적 측면에서는, synthetic/proxy 데이터를 성능 향상 수단이 아니라 원본 데이터 없이도 평가를 가능하게 하는 대체 평가 수단으로 재정의했다는 점이 중요하다. 이는 의료 AI 벤치마크를 “데이터셋”이 아니라 “평가 방법”의 관점에서 확장하는 시도로 볼 수 있으며,

[4] 이화여자대학교 의료원과의 협력을 바탕으로 실제 의료데이터 기반 평가 수행 예정

병원 내부 실제 평가 결과와 외부 proxy 평가 결과 사이의 정합성을 검증함으로써 privacy-preserving evaluation의 가능성을 탐색한다는 학술적 의미를 가진다. 또한 성능이 다른 여러 모델에 대해 내부 평가와 외부 평가의 일치 정도를 비교함으로써, 제안한 방법이 단순한 예외적 사례가 아니라 일반적인 benchmark method로 기능할 수 있는지를 확인할 수 있다.

실용적 측면에서는, 의료기관이 민감한 원본 데이터를 외부에 제공하지 않아도 새로운 환경에서 AI 모델이 얼마나 신뢰 가능하고 활용 가능한지 사전에 검증할 수 있는 기반을 마련한다. 특히 대형 공개 데이터셋에서 높은 성능을 보인 모델이 실제 병원 환경에서도 유사하게 작동하는지 확인할 수 있으므로, 의료 AI의 도입 전 검증과 품질 관리 체계를 지원하는 데 활용될 수 있다. 나아가 중앙 서버에는 원본이 아닌 평가 결과와 비식별화된 정보만 집계하는 구조를 통해, 보안성과 운영 가능성을 동시에 고려한 현실적 benchmark framework로 확장될 수 있다는 가능성을 보여준다.

2.5. 주요 기능 리스트

의료 데이터 반출 제한 환경에서 의료 AI 모델의 성능을 검증하기 위해서는 원본 데이터를 외부로 공유하지 않으면서도 병원 내부 평가와 외부 평가를 연결할 수 있는 구조가 필요하다. 이에 따라 병원 내부 실제 평가와 병원 외부 프록시 평가를 연계하고, 두 결과의 유사성을 검토할 수 있는 의료 AI 평가 프레임워크를 구성하였다. 주요 구성 요소는 다음과 같다.

2.5.1 병원 내부 실제 평가

의료 기관 내부의 원본 테스트 데이터를 활용하여 의료 AI 모델의 실제 성능을 산출한다. 각 기관은 자체 보유한 ECG, X-ray 등 의료 데이터를 병원 내부 보안 환경에서만 사용하며, 외부로는 원본 데이터를 반출하지 않는다. 이 과정에서 AUROC, AUPRC 등의 표준 성능 지표를 계산하고, 이를 내부 real evaluation 결과로 확보한다. 해당 결과는 이후 외부 프록시 평가 결과와 비교되는 기준값으로 활용된다.

2.5.2 Feature 정보 추출

병원 내부에서 원본 데이터를 모델에 입력한 뒤, 원본 데이터 자체가 아니라 모델의 feature vector를 추출하는 기능이다. 이 기능은 데이터 비공유 환경을 유지하면서도 외부 프록시 평가에 사용할 중간 표현만 전달하도록 하는 기능이며, privacy-preserving benchmark method의 기반이 된다.

2.5.3 비식별화 통계 정보 생성

Feature vector를 직접 공유하기 어려운 경우를 대비하여, 병원 내부에서 클래스별 mean vector, covariance, sample count, 필요 시 subcluster별 mean/covariance를 계산하는 기능이다. 이는 feature 전체 대신 통계 요약값만 외부에 제공하는 평가 지원 기능으로,

proxy feature set을 생성하기 위한 분포 정보로 사용된다. 특히 class-wise covariance를 이용해 각 클래스 feature가 어떤 방향과 크기로 퍼져 있는지를 반영할 수 있도록 설계한다.

2.5.4 Proxy evaluation set 구성

병원 내부에서 전달된 feature 정보 또는 통계 정보를 바탕으로 병원 외부 평가용 대체 데이터셋을 구성한다. 이때 생성되는 proxy evaluation set은 원본 환자 데이터를 복원하는 것이 아니라, 원본 없이도 평가가 가능하도록 설계된 대체 평가용 세트이다. 구성 방식으로는 익명화된 feature의 직접 활용, 클래스별 평균과 공분산 기반 샘플링, feature interpolation, covariance 방향 perturbation 등이 가능하다. 이 단계는 외부 평가 환경에서 실제 병원 내부 데이터의 feature-space 특성을 어느 정도 반영할 수 있는지를 좌우하는 핵심 구성 요소에 해당한다.

병원 외부에서는 병원 내부에서 전달한 정보의 수준에 따라 proxy 데이터를 두 방식으로 구성한다. 첫째, 병원 내부에서 샘플 단위의 feature vector를 전달할 수 있는 경우에는, 해당 feature vector를 익명화된 평가 표현으로 사용하여 외부 proxy evaluation set을 구성한다. 이때 원본 ECG나 X-ray는 외부로 전달되지 않으며, 외부에서는 feature vector, 예측 score, uncertainty, subgroup 정보 등 원본을 직접 복원할 수 없는 중간 표현만 활용한다.

둘째, 샘플 단위 feature 자체도 외부 제공이 어려운 경우에는, 병원 내부에서 계산한 class-wise mean, covariance, sample count 등의 통계치를 전달받아, 외부에서 이 분포 정보를 기반으로 proxy feature를 생성한다. 예를 들어 각 클래스별 평균 벡터와 공분산을 이용해 feature 공간에서 synthetic feature set을 구성할 수 있다.

이렇게 생성된 proxy 데이터는 원본 환자 데이터를 재현하기 위한 것이 아니라, 원본 없이도 병원 내부 실제 평가와 유사한 성능 지표를 산출할 수 있는 feature-level의 대체 평가셋으로 사용된다.

2.5.5 외부 프록시 평가 수행 및 비교·분석

proxy evaluation set을 구성한 뒤, 이를 기반으로 병원 외부에서 평가 대상 모델의 외부 성능 평가를 수행한다. 외부 proxy 평가에서도 AUROC, AUPRC 등 병원 내부 실제 평가와 동일한 기준으로 성능 지표를 산출하고, 내부 실제 평가 결과와 1:1로 대응하여 비교하여 proxy 평가의 타당성을 검증한다. 이때 모델별 순위의 일관성, 성능 차이의 크기, 전체적인 성능 경향의 유사성을 함께 분석함으로써, 원본 데이터 반출 없이도 외부 평가가 내부 실제 평가를 어느 수준까지 근사할 수 있는지 실험적으로 확인한다.

2.5.6 평가 결과 종합 및 방법론 검증

내부 실제 평가, feature 및 통계 정보 기반 프록시 평가, 그리고 두 결과 간 비교 분석을 종합하여 전체 프레임워크의 타당성을 정리한다. 이 과정에서는 어떤 종류의 feature 또는 통계 정보가 외부 평가에 더 유효한지, 어떤 방식의 proxy set 구성이 실제 평가 결과를 더 잘 반영하는지, 그리고 제안한 구조가 의료 데이터 반출 제한 환경에서 적용 가능한 평가

방법론으로 기능할 수 있는지를 종합적으로 검토한다. 이를 통해 의료 데이터 비공개 환경에서 활용 가능한 의료 AI 평가 방법론의 기본 방향을 도출하고자 한다.

3. Project-Design

3.1. 요구사항 정의

본 프레임워크의 목표 사용자는 의료 AI 모델의 실제 임상 적용 가능성을 검토하는 의료기관과, 개발한 모델의 일반화 성능과 현장 적용 가능성을 검증해야 하는 의료 AI 모델 개발 주체이다. 의료기관은 원본 데이터 유출 없이 안전한 환경에서 모델을 평가하고 도입 여부를 판단할 수 있어야 하며, 의료 AI 모델 개발 주체는 새로운 병원 환경에서도 모델 성능이 유지되는지 객관적으로 입증할 수 있어야 한다. 그러나 의료데이터는 개인정보 보호와 보안 규제로 인해 외부 반출이 어렵기 때문에, 실제 임상 환경을 반영한 성능 검증이 쉽지 않다는 문제가 있다. 따라서 본 시스템에는 병원 내부 원본 데이터 기반 실제 평가 기능, feature vector 또는 통계치 기반 proxy 평가 기능, 내부 실제 평가와 외부 proxy 평가 결과의 유사성 검증 기능, 그리고 평가 결과를 통합 관리할 수 있는 benchmark 관리 기능이 요구된다. 이를 통해 원본 데이터 반출 없이도 안전하고 객관적인 의료 AI 평가 체계를 제공하고자 한다.

3.2. 전체시스템 구성

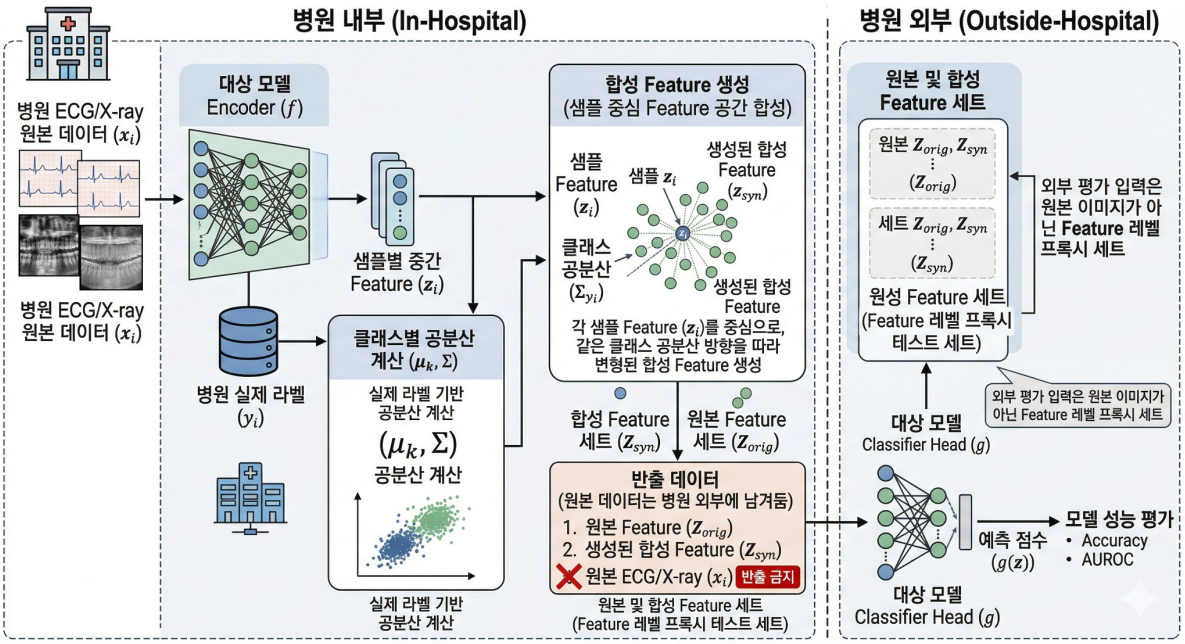

전체 시스템은 병원 내부와 병원 외부의 이중 구조로 구성된다. 병원 내부에서는 원본 ECG·X-ray 데이터를 encoder f에 입력하여 샘플별 중간 feature Z_i 를 추출하고, 실제 정답 라벨을 기반으로 클래스별 평균과 공분산을 계산한다. 이후 각 샘플 feature를 중심으로

동일 클래스 공분산 방향을 따라 synthetic feature를 생성하여, 원본 feature와 합성 feature로 이루어진 feature-level proxy test set을 구성한다. 이때 원본 raw data는 외부로 반출되지 않으며, 반출 가능한 정보는 feature-level 세트에 한정된다. 병원 외부에서는 전달받은 원본 및 합성 feature 세트를 classifier head g에 입력하여 예측 점수를 계산하고, Accuracy, AUROC 등의 성능 지표를 산출한다. 최종적으로 병원 내부 실제 평가 결과와 병원 외부 프록시 평가 결과를 비교함으로써, 원본 데이터 비반출 환경에서 feature-space 기반 대체 평가의 타당성을 검증한다.