

의료 데이터 반출 제한 환경에서의
연합 평가 및 합성 데이터 기반
의료 **AI** 평가 프레임워크

02 MBP

김채영, 정지현

1. Team Info

1.1. 과제(논문)명

- 의료 데이터 반출 제한 환경에서의 연합 평가 및 합성 데이터 기반 의료 AI 평가 프레임워크
- A Medical AI Evaluation Framework Based on Federated Evaluation and Synthetic Data under Medical Data Transfer Restrictions

1.2. 팀 정보

- 02
- MBP
- 연구트랙

1.3. 팀 구성원

- 김채영(2271021) : 리더, 프로젝트 기획, 평가 파이프라인 설계, 시스템 구조 설계
- 정지현(2371055) : 데이터 전처리 및 실험 설계, 프록시 평가 구조 구현

2. Project-Summary

2.1. 문제 정의

2.1.1 연구의 배경 및 필요성

최근 의료 인공지능(AI)은 질환 예측, 영상 판독, 임상 의사결정 지원 등 다양한 영역에서 활용 가능성을 확대하고 있다. 그러나 의료 AI 모델이 실제 임상 현장에서 활용되기 위해서는 특정 데이터셋에서 높은 성능을 보이는 것만으로는 충분하지 않다. 의료기관마다 환자 구성, 질환 분포, 검사 장비, 촬영 조건, 데이터 품질, 판독 기준 등이 서로 다르기 때문에, 한 기관이나 공개 데이터셋에서 우수한 결과를 보인 모델이라 하더라도 다른 기관 환경에서 동일한 수준의 성능과 신뢰성을 유지한다고 보기 어렵다. 따라서 의료 AI의 실질적인 활용 가능성을 판단하기 위해서는 다양한 기관 환경에서의 일반화 성능과 안정성을 검증할 수 있는 평가 체계가 필요하다.

실제 의료 데이터는 개인정보 보호, 병원 보안 규정, 법적 제한 등으로 인해 외부 반출이 어려워, 여러 기관의 원본 데이터를 통합해 평가하는 방식은 현실적으로 제약이 크다. 그 결과로 의료 AI 평가는 공개 데이터셋이나 단일 기관 데이터에 의존하는 경우가 많다. 이는 실제 의료 환경의 다양성과 기관 간 데이터 이질성을 충분히 반영하지 못하며, 다기관 환경에서 발생할 수 있는 성능 저하나 일반화 한계를 사전에 확인하기 어렵다는 문제를 가진다. 또한 의료기관에서는 테스트 데이터 자체가 부족한 경우가 많고, 특히 희귀 사례나 경계 사례는 충분히 확보하기 어려워 모델의 취약성과 강건성을 폭넓게 평가하기 어렵다. 따라서 의료 데이터 반출 제한이라는 현실적 제약을 전제로 하면서도, 다기관 환경과 데이터 부족 문제를 함께 고려할 수 있는 새로운 의료 AI 평가 방법론이 필요하다.

2.2.2 연구 목적

연구의 목적은 의료 데이터 반출이 제한된 환경에서 원본 환자 데이터를 외부로 공유하지 않고도 의료 AI 모델의 성능을 평가할 수 있는 방법론적 프레임워크를 제안하는 것이다.

이를 위해 각 의료기관은 자체 보유한 원본 데이터를 기관 내부의 보안 환경에서만 사용하여 동일한 평가 절차를 수행하고, 동시에 원본 데이터로부터 추출한 특징 표현 또는 통계치를 기반으로 합성 데이터를 생성한다. 이후 기관 외부에서는 이 합성 데이터를 이용해 프록시 평가를 수행하고, 내부 **real evaluation** 결과와 외부 **proxy evaluation** 결과를 비교·분석함으로써, 프록시 데이터가 원본 데이터를 대체하는 평가 수단으로서 어느 정도의 충실도와 타당성을 가지는지를 검증하고자 한다. 즉, 합성 데이터의 임상적 정확도를 직접

입증하는 것이 아니라, 프록시 데이터가 실제 평가를 얼마나 잘 근사하는 평가 대체물로 기능할 수 있는지를 확인하는 데 초점을 둔다.

2.2. 기존 연구와의 비교

2.2.1 MedPerf¹

MedPerf는 의료 AI 모델을 다양한 기관의 데이터로 평가하기 위해, 데이터를 외부로 공유하지 않고 모델을 데이터가 있는 기관으로 보내어 성능을 검증하는 **federated evaluation**(연합 평가) 플랫폼을 제안한 연구이다. 논문은 의료 AI의 실제 적용을 위해서는 대규모·다기관 데이터에 대한 일반화 성능 검증이 필요하지만, 개인정보 보호, 규제, 비용 등의 문제로 데이터 공유가 어렵다는 점을 문제로 제시한다. 이를 해결하기 위해 MedPerf는 데이터 대신 모델을 각 기관으로 배포하고, 각 기관은 로컬 환경에서 모델을 실행한 뒤 성능 지표만 중앙으로 제출하는 구조를 채택하였다. 즉, 원본 데이터를 외부로 반출하지 않으면서도 다기관 환경에서 모델 성능을 검증할 수 있도록 한 플랫폼 중심의 접근이다. 또한 평가 결과는 집계된 **metric** 중심으로 관리되며, 실제로 여러 기관과 파일럿 스터디를 통해 플랫폼의 확장성과 실사용 가능성을 검증하였다.

본 연구 역시 원본 의료데이터를 외부로 반출하지 않고 병원 내부에서 평가를 수행한다는 점에서 MedPerf와 유사하다. 그러나 MedPerf는 기존 모델을 각 기관 데이터로 평가하는 **federated benchmarking platform**에 초점을 둔 반면, 본 연구는 병원 내부 실제 평가 결과를 외부의 **proxy** 평가로 어느 정도 근사할 수 있는지 검증하는 **privacy-preserving benchmark method**를 제안한다는 점에서 차이가 있다. 즉, MedPerf는 “모델을 데이터가 있는 곳으로 보내 평가한다”는 평가 인프라 자체에 집중하고, 본 연구는 “원본을 공유하지 않고도 외부에서 대체 평가가 가능한가”라는 방법론에 집중한다.

2.2.2 SF(DA)²

SF(DA)²는 **source-free domain adaptation** 상황에서, 원본 **source domain** 데이터를 사용하지 않고도 새로운 **target domain**에 모델을 적응시키기 위한 방법을 제안한 연구이다. 이 논문은 기존 SFDA 기법들이 데이터 증강을 활용할 때 **class-preserving transformation**에 대한 사전지식이 필요하고, 증강 샘플 수가 많아질수록 연산량과 메모리 사용량이 증가한다는 한계를 지적한다. 이를 해결하기 위해 **pretrained model**의 **feature space**에서

¹ Alexandros Karargyris et al., “Federated benchmarking of medical artificial intelligence with MedPerf,” *Nature Machine Intelligence*, vol. 5, no. 7, pp. 799–810, 2023.

² Hwang et al., “SF(DA)²: Source-free Domain Adaptation Through the Lens of Data Augmentation,” *ICLR* 2024.

target feature 간 이웃 관계를 이용해 augmentation graph를 구성하고, spectral neighborhood clustering, implicit feature augmentation, feature disentanglement를 통해 명시적 증강 없이도 target domain adaptation 성능을 높이는 방법을 제안하였다. 즉, 핵심 목적은 원본 source 데이터 없이 target domain에 모델을 더 잘 적응시키는 것이며, feature space와 통계적 구조를 활용한다는 점이 특징이다.

본 연구는 SF(DA)²와 마찬가지로 데이터를 직접 공유하지 않고 feature-level 정보나 통계적 정보를 활용한다는 유사성이 있다. 특히 두 연구 모두 병원 내부에서 원본 데이터를 모델에 넣어 feature vector 또는 그 통계치를 추출하고, 병원 외부에서는 이를 바탕으로 proxy 데이터를 구성하고, feature space를 활용해 원본 데이터 없이 다른 목적의 연산을 수행한다는 점이 공통적이다. 그러나 SF(DA)²는 도메인 차이를 줄여 target domain에서의 모델 성능을 향상시키는 adaptation 연구이고, 본 연구는 병원 내부 실제 평가 결과를 외부 proxy 평가로 얼마나 잘 근사할 수 있는지 검증하는 benchmark 연구이다. 따라서 SF(DA)²의 feature augmentation은 adaptation 성능 개선을 위한 것이지만, FedSyn-MedBench에서의 synthetic/proxy 구성은 학습용 데이터 증강이 아니라 외부 평가를 위한 대체 evaluation set 구성이라는 점에서 사용 목적이 다르다.

2.2.3 Real-world prediction of preclinical Alzheimer's disease with a deep generative model ³

해당 연구는 알츠하이머병의 초기 지표인 amyloid positivity를 직접적으로 검사하는 대신, structural MRI, 인구통계 변수, 인지검사 점수와 같은 proxy measure를 활용하여 예측하는 deep generative model을 제안한 논문이다. 논문은 실제 임상 데이터가 missing feature, missing label, class imbalance와 같은 불완전성(imperfect dataset)을 자주 포함한다는 점을 문제로 제시하고, 이를 해결하기 위해 HexaGAN 기반의 생성모델 구조를 확장하여 고차원 영상 데이터와 표 형식 임상 데이터를 함께 처리하는 방식을 제안하였다. 또한 학습 데이터와 실제 적용 데이터의 feature set이나 진단 기준이 다르더라도 모델이 적응적으로 작동할 수 있음을 강조하며, 서로 다른 병원 환경에서도 활용 가능한 real-world clinical translation 가능성을 보여주었다. 즉, 직접 측정이 어렵거나 비용 부담이 큰 임상 대상을 proxy measure로 대체하여 예측하고, missing feature, missing label, class imbalance가

³ Hwang et al., "Real-world prediction of preclinical Alzheimer's disease with a deep generative model," *Artificial Intelligence in Medicine*, vol. 144, article 102654, 2023.

존재하는 실제 의료데이터 환경에서도 활용 가능하도록 **generative model**을 설계한 연구이다.

본 연구는 해당 논문과 마찬가지로 원본 의료데이터를 직접 외부에 공유하지 않고, 대체 가능한 표현 또는 **proxy** 정보를 활용한다는 점에서 유사성이 있다. 특히 두 연구 모두 의료데이터가 원본 그대로 주어지지 않는다는 현실을 전제로 하며, 다른 형태의 정보를 활용해 실제 임상 환경에서 적용 가능한 방법을 모색한다는 공통점이 있다. 그러나 **Alzheimer generative model** 연구는 직접 측정이 어려운 임상 **target**을 **proxy measure**로 예측하는 진단 모델 연구인 반면, 본 연구는 병원 내부 실제 평가 결과를 병원 외부의 **proxy** 평가가 얼마나 잘 근사할 수 있는지 검증하는 **benchmark method** 연구라는 점에서 차이가 있다. 다시 말해, 해당 연구가 “**proxy measure**를 활용해 질환 여부를 예측하는 것”에 초점을 둔다면, 본 연구는 “원본 데이터를 공유하지 않고도 외부에서 대체 평가가 가능한가”를 다룬다. 따라서 이 연구는 본 연구의 직접적인 구조적 선행연구라기보다는, **proxy** 개념의 의료 적용 가능성과 불완전한 의료데이터 환경에서의 **generative modeling** 활용 가능성을 보여주는 참고 연구로 위치지을 수 있다.

2.3. 제안 내용

의료 **AI**는 다양한 환경에서 실제로 사용되기 전에 충분한 성능 검증이 필요하지만, 의료데이터는 개인정보 보호와 규제 문제로 인해 외부 반출이 어렵기 때문에 병원별 실제 환경을 반영한 평가를 수행하기가 쉽지 않다. 이로 인해 대형 데이터셋에서 높은 성능을 보인 모델이라 하더라도, 새로운 병원 환경에서도 동일하게 신뢰할 수 있는지 검증하기 어렵다는 문제가 발생한다.

본 연구는 이러한 한계를 해결하기 위해, 원본 의료데이터를 외부로 공유하지 않으면서도 평가가 가능하도록 병원 내부 실제 평가와 병원 외부 **proxy** 평가를 결합한 **privacy-preserving benchmark method**를 제안한다. 구체적으로 병원 내부에서는 원본 **ECG**, **X-ray** 데이터를 이용해 실제 성능을 평가하고⁴, 동시에 **feature vector** 또는 그 통계치를 추출한다. 이후 병원 외부에서는 이 비식별 중간 표현을 바탕으로 **proxy evaluation set**을 구성하여 동일한 모델의 성능을 다시 산출하고, 이를 병원 내부 실제 평가 결과와 비교함으로써 외부 평가가 실제 평가를 어느 정도 근사할 수 있는지를 검증한다.

⁴ 이화여자대학교 의료원과의 협력을 바탕으로 실제 의료데이터 기반 평가 수행 예정

즉, 본 연구의 해결책은 원본 데이터 반출 없이도 의료 AI의 성능을 검증할 수 있는 대체 평가 체계를 설계하고, 이를 통해 데이터 공유 제약이 큰 의료 환경에서도 활용 가능한 **benchmark method**를 구축하는 데 있다.

2.4. 기대 효과 및 의의

병원 원본 데이터를 외부로 반출하지 않고도 의료 AI 모델을 평가할 수 있는 **privacy-preserving benchmark method**를 제안한다는 점에서 의의가 있다. 실제 의료 현장에서는 개인정보 보호와 데이터 반출 제한으로 인해 병원 데이터를 직접 활용해 모델 성능을 검증하기 어렵다. 본 과제는 이러한 한계를 해결하기 위해, 병원 내부에서는 원본 ECG·X-ray 데이터로 실제 평가를 수행하고, 외부에서는 원본 대신 모델의 **feature vector** 또는 그 통계치만을 활용해 **proxy** 평가를 수행한 뒤, 두 결과의 유사성을 검증하는 구조를 설계하였다. 즉, 데이터 공유가 어려운 환경에서도 원본 성능을 근사할 수 있는 평가 방법론 자체를 제안한다는 점에서 기존의 단순 데이터셋 구축이나 모델 개발 중심 접근과 차별화된다.

연구적 측면에서는, **synthetic/proxy** 데이터를 성능 향상 수단이 아니라 원본 데이터 없이도 평가를 가능하게 하는 대체 평가 수단으로 재정의했다는 점이 중요하다. 이는 의료 AI 벤치마크를 “데이터셋”이 아니라 “평가 방법”의 관점에서 확장하는 시도로 볼 수 있으며, 병원 내부 실제 평가 결과와 외부 **proxy** 평가 결과 사이의 정합성을 검증함으로써 **privacy-preserving evaluation**의 가능성을 탐색한다는 학술적 의미를 가진다. 또한 성능이 다른 여러 모델에 대해 내부 평가와 외부 평가의 일치 정도를 비교함으로써, 제안한 방법이 단순한 예외적 사례가 아니라 일반적인 **benchmark method**로 기능할 수 있는지를 확인할 수 있다.

실용적 측면에서는, 의료기관이 민감한 원본 데이터를 외부에 제공하지 않아도 새로운 환경에서 AI 모델이 얼마나 신뢰 가능하고 활용 가능한지 사전에 검증할 수 있는 기반을 마련한다. 특히 대형 공개 데이터셋에서 높은 성능을 보인 모델이 실제 병원 환경에서도 유사하게 작동하는지 확인할 수 있으므로, 의료 AI의 도입 전 검증과 품질 관리 체계를 지원하는 데 활용될 수 있다. 나아가 중앙 서버에는 원본이 아닌 평가 결과와 비식별화된 정보만 집계하는 구조를 통해, 보안성과 운영 가능성을 동시에 고려한 현실적 **benchmark framework**로 확장될 수 있다는 가능성을 보여준다.

2.5. 주요 기능 리스트

의료 데이터 반출 제한 환경에서 의료 AI 모델의 성능을 검증하기 위해서는 원본 데이터를 외부로 공유하지 않으면서도 병원 내부 평가와 외부 평가를 연결할 수 있는 구조가 필요하다. 이에 따라 병원 내부 실제 평가와 병원 외부 프록시 평가를 연계하고, 두 결과의 유사성을 검토할 수 있는 의료 AI 평가 프레임워크를 구성하였다. 주요 구성 요소는 다음과 같다.

2.5.1 병원 내부 실제 평가

의료 기관 내부의 원본 테스트 데이터를 활용하여 의료 AI 모델의 실제 성능을 산출한다. 각 기관은 자체 보유한 ECG, X-ray 등 의료 데이터를 병원 내부 보안 환경에서만 사용하며, 외부로는 원본 데이터를 반출하지 않는다. 이 과정에서 AUROC, AUPRC 등의 표준 성능 지표를 계산하고, 이를 내부 **real evaluation** 결과로 확보한다. 해당 결과는 이후 외부 프록시 평가 결과와 비교되는 기준값으로 활용된다.

2.5.2 Feature 정보 추출

병원 내부에서 원본 데이터를 모델에 입력한 뒤, 원본 데이터 자체가 아니라 모델의 **feature vector**를 추출하는 기능이다. 이 기능은 데이터 비공유 환경을 유지하면서도 외부 프록시 평가에 사용할 중간 표현만 전달하도록 하는 기능이며, **privacy-preserving benchmark method**의 기반이 된다.

2.5.3 비식별화 통계 정보 생성

Feature vector를 직접 공유하기 어려운 경우를 대비하여, 병원 내부에서 클래스별 **mean vector**, **covariance**, **sample count**, 필요 시 **subcluster**별 **mean/covariance**를 계산하는 기능이다. 이는 **feature** 전체 대신 통계 요약값만 외부에 제공하는 평가 지원 기능으로, **proxy feature set**을 생성하기 위한 분포 정보로 사용된다. 특히 **class-wise covariance**를 이용해 각 클래스 **feature**가 어떤 방향과 크기로 퍼져 있는지를 반영할 수 있도록 설계한다.

2.5.4 Proxy evaluation set 구성

병원 내부에서 전달된 **feature** 정보 또는 통계 정보를 바탕으로 병원 외부 평가용 대체 데이터셋을 구성한다. 이때 생성되는 **proxy evaluation set**은 원본 환자 데이터를 복원하는 것이 아니라, 원본 없이도 평가가 가능하도록 설계된 대체 평가용 세트이다. 구성 방식으로는 익명화된 **feature**의 직접 활용, 클래스별 평균과 공분산 기반 샘플링, **feature**

interpolation, covariance 방향 perturbation 등이 가능하다. 이 단계는 외부 평가 환경에서 실제 병원 내부 데이터의 **feature-space** 특성을 어느 정도 반영할 수 있는지를 좌우하는 핵심 구성 요소에 해당한다.

병원 외부에서는 병원 내부에서 전달한 정보의 수준에 따라 **proxy** 데이터를 두 방식으로 구성한다. 첫째, 병원 내부에서 샘플 단위의 **feature vector**를 전달할 수 있는 경우에는, 해당 **feature vector**를 익명화된 평가 표현으로 사용하여 외부 **proxy evaluation set**을 구성한다. 이때 원본 ECG나 X-ray는 외부로 전달되지 않으며, 외부에서는 **feature vector**, 예측 **score**, **uncertainty**, **subgroup** 정보 등 원본을 직접 복원할 수 없는 중간 표현만 활용한다.

둘째, 샘플 단위 **feature** 자체도 외부 제공이 어려운 경우에는, 병원 내부에서 계산한 **class-wise mean**, **covariance**, **sample count** 등의 통계치를 전달받아, 외부에서 이 분포 정보를 기반으로 **proxy feature**를 생성한다. 예를 들어 각 클래스별 평균 벡터와 공분산을 이용해 **feature** 공간에서 **synthetic feature set**을 구성할 수 있다.

이렇게 생성된 **proxy** 데이터는 원본 환자 데이터를 재현하기 위한 것이 아니라, 원본 없이도 병원 내부 실제 평가와 유사한 성능 지표를 산출할 수 있는 **feature-level**의 대체 평가셋으로 사용된다.

2.5.5 외부 프록시 평가 수행 및 비교·분석

proxy evaluation set을 구성한 뒤, 이를 기반으로 병원 외부에서 평가 대상 모델의 외부 성능 평가를 수행한다. 외부 **proxy** 평가에서도 **AUROC**, **AUPRC** 등 병원 내부 실제 평가와 동일한 기준으로 성능 지표를 산출하고, 내부 실제 평가 결과와 1:1로 대응하여 비교하여 **proxy** 평가의 타당성을 검증한다. 이때 모델별 순위의 일관성, 성능 차이의 크기, 전체적인 성능 경향의 유사성을 함께 분석함으로써, 원본 데이터 반출 없이도 외부 평가가 내부 실제 평가를 어느 수준까지 근사할 수 있는지 실험적으로 확인한다.


2.5.6 평가 결과 종합 및 방법론 검증

내부 실제 평가, **feature** 및 통계 정보 기반 프록시 평가, 그리고 두 결과 간 비교 분석을 종합하여 전체 프레임워크의 타당성을 정리한다. 이 과정에서는 어떤 종류의 **feature** 또는 통계 정보가 외부 평가에 더 유효한지, 어떤 방식의 **proxy set** 구성이 실제 평가 결과를 더 잘 반영하는지, 그리고 제안한 구조가 의료 데이터 반출 제한 환경에서 적용 가능한 평가 방법론으로 기능할 수 있는지를 종합적으로 검토한다. 이를 통해 의료 데이터 비공개 환경에서 활용 가능한 의료 AI 평가 방법론의 기본 방향을 도출하고자 한다.

3. Project-Design

3.1. 요구사항 정의

본 프레임워크의 목표 사용자는 의료 AI 모델의 실제 임상 적용 가능성을 검토하는 의료기관과, 개발한 모델의 일반화 성능과 현장 적용 가능성을 검증해야 하는 의료 AI 모델 개발 주체이다. 의료기관은 원본 데이터 유출 없이 안전한 환경에서 모델을 평가하고 도입 여부를 판단할 수 있어야 하며, 의료 AI 모델 개발 주체는 새로운 병원 환경에서도 모델 성능이 유지되는지 객관적으로 입증할 수 있어야 한다. 그러나 의료데이터는 개인정보 보호와 보안 규제로 인해 외부 반출이 어렵기 때문에, 실제 임상 환경을 반영한 성능 검증이 쉽지 않다는 문제가 있다. 따라서 본 시스템에는 병원 내부 원본 데이터 기반 실제 평가 기능, feature vector 또는 통계치 기반 proxy 평가 기능, 내부 실제 평가와 외부 proxy 평가 결과의 유사성 검증 기능, 그리고 평가 결과를 통합 관리할 수 있는 benchmark 관리 기능이 요구된다. 이를 통해 원본 데이터 반출 없이도 안전하고 객관적인 의료 AI 평가 체계를 제공하고자 한다.



3.2. 전체시스템 구성

전체 시스템은 병원 내부와 병원 외부의 이중 구조로 구성된다. 병원 내부에서는 원본

ECG·X-ray 데이터를 encoder f 에 입력하여 샘플별 중간 feature Z_i 를 추출하고, 실제 정답 라벨을 기반으로 클래스별 평균과 공분산을 계산한다. 이후 각 샘플 feature를 중심으로 동일 클래스 공분산 방향을 따라 synthetic feature를 생성하여, 원본 feature와 합성 feature로 이루어진 feature-level proxy test set을 구성한다. 이때 원본 raw data는 외부로 반출되지 않으며, 반출 가능한 정보는 feature-level 세트에 한정된다. 병원 외부에서는 전달받은 원본 및 합성 feature 세트를 classifier head g 에 입력하여 예측 점수를 계산하고, Accuracy, AUROC 등의 성능 지표를 산출한다. 최종적으로 병원 내부 실제 평가 결과와 병원 외부 프록시 평가 결과를 비교함으로써, 원본 데이터 비반출 환경에서 feature-space 기반 대체 평가의 타당성을 검증한다.

3.3. 주요 엔진 및 기능 설계

본 연구에서 제안하는 프레임워크는 의료 데이터 반출이 제한된 환경에서도 의료 AI 모델의 성능을 검증할 수 있도록, 병원 내부 평가와 병원 외부 프록시 평가를 연계하는 구조로 설계하였다. 전체 시스템은 원본 의료 데이터를 병원 내부에서만 활용하는 real evaluation 단계와, 병원 내부에서 추출된 feature-level 정보를 바탕으로 병원 외부에서 대체 평가를 수행하는 proxy evaluation 단계로 구성된다. 이를 통해 원본 ECG 또는 X-ray 데이터를 외부로 반출하지 않으면서도, 외부 환경에서 모델 성능을 어느 정도 근사적으로 평가할 수 있는지를 확인한다.

이를 위해 먼저 평가 태스크를 명확히 설정한다. 의료 AI 평가 프레임워크의 타당성을 검증하기 위해, 임상적으로 의미가 있으면서도 라벨이 비교적 명확하고, proxy evaluation 구조를 적용하기 쉬운 단순 분류 태스크를 우선적으로 선정한다. 특히 치과 파노라마 X-ray의 경우 이미지 단위에서 존재 여부를 판단할 수 있는 multi-label classification task로 설정한다. 이는 한 장의 파노라마 이미지에 대해 여러 치과 소견의 존재 여부를 동시에 판단하는 방식이다.

라벨 설정 단계에서는 병원 리포트나 차팅에서 자주 등장하는 치과 소견 후보를 수집한 뒤, 이미지 단위 라벨링 가능성, 라벨의 명확성, 충분한 표본 수 확보 가능성, backbone feature로 표현 가능한지 여부를 기준으로 최종 라벨을 선정한다. 치과 파노라마 데이터의 경우 치아 우식, 치근단 병소, 잔존치근, 치주골 소실, 매복치와 같이 파노라마 전체 영상에서 비교적 존재 여부를 판단할 수 있는 소견이 후보가 된다. 반면 치아 단위 crop 없이는 판별이 어려운 미세 소견, 중증도처럼 경계가 모호한 라벨, 양성 표본 수가 지나치게

적은 라벨, **detection**이나 **segmentation**이 사실상 필요한 라벨은 제외한다.

심전도 데이터의 경우에도 동일하게 **image-level**이 아닌 **signal-level multi-label classification task**로 설정할 수 있다. 이때 라벨은 ECG 신호에서 임상적으로 의미가 크고, 공개 모델 또는 병원 데이터에서 비교적 다루기 쉬운 진단명을 중심으로 구성한다. 현재 후보 라벨은 AF, 1° AVB, RBBB, PVC, LBBB 이다. 이들은 심전도 기반 AI 모델에서 자주 다루어지는 부정맥 또는 전도 이상 소견이며, 5개 라벨에 대한 **multi-label classification head**를 붙여 평가 모델을 구성할 수 있다.

태스크와 라벨이 설정되면, 병원 내부에서는 원본 데이터를 활용한 **real evaluation**을 수행한다. 치과 파노라마 X-ray의 경우 원본 이미지를 모델의 **encoder**와 **classifier head**에 입력하여 각 라벨에 대한 예측 **score**를 산출한다. 심전도 데이터의 경우에도 원본 ECG 신호를 모델에 입력하여 AF, 1° AVB, RBBB, PVC, LBBB 각각에 대한 예측 확률을 계산한다. 이 과정에서 원본 데이터는 병원 내부에서만 사용되며, 외부로 반출되지 않는다. 산출된 예측 **score**는 실제 라벨과 비교되어 **AUROC**, **AUPRC** 등의 지표로 변환된다. 이 내부 평가 결과는 이후 **proxy evaluation** 결과와 비교되는 기준값으로 활용된다.

다음 단계에서는 원본 데이터를 모델의 **encoder**에 입력하여 **classifier** 직전 단계의 **feature vector**를 추출한다. 이 **feature vector**는 원본 이미지나 ECG 신호 자체가 아니라 모델이 입력 데이터로부터 학습한 중간 표현이다. 따라서 원본 데이터를 직접 공유하지 않고도 모델 평가에 필요한 정보를 일부 전달할 수 있는 대체 표현으로 활용된다. 다만 **feature vector** 역시 원본 데이터에서 유래한 정보이므로, 실제 적용 시에는 익명화, 차원 축소 등의 개인정보 보호 절차를 함께 고려해야 한다.

Feature vector 자체를 외부에 제공하기 어려운 경우를 대비하여, 병원 내부에서는 **class-wise statistics**도 함께 생성한다. 각 라벨 또는 클래스별로 **feature vector**를 모은 뒤 평균 벡터, 공분산 행렬, **sample count**를 계산한다. 평균 벡터는 해당 클래스 **feature**의 중심을 나타내고, 공분산 행렬은 **feature**가 어떤 방향과 크기로 퍼져 있는지를 보여준다. 외부에서는 이 통계 정보를 바탕으로 원본 **feature**의 분포를 근사하는 **synthetic feature**를 생성할 수 있다.

병원 외부의 **proxy evaluation** 단계에서는 병원 내부에서 전달받은 **feature vector** 또는 **class-wise statistics**를 기반으로 **proxy evaluation set**을 구성한다. 샘플 단위 **feature vector** 공유가 가능한 경우에는 이를 익명화된 평가 표현으로 사용하고, **feature** 공유가 어려운

경우에는 클래스별 평균과 공분산을 이용해 **synthetic feature**를 생성한다. 이때 생성되는 **synthetic feature**는 실제 환자 데이터를 복원하기 위한 것이 아니라, 실제 평가 결과를 근사하기 위한 **feature-level** 대체 평가 데이터로 정의된다.

외부 **proxy evaluation**에서는 원본 데이터에 접근하지 않고 **proxy feature**만을 **classifier head**에 입력하여 예측 **score**를 산출한다. 이후 내부 **real evaluation**과 동일한 지표를 사용해 **proxy AUROC**, **proxy AUPRC**를 계산한다. 최종적으로 두 평가 결과를 비교함으로써, **proxy evaluation**이 **real evaluation**을 얼마나 잘 근사하는지 분석한다. 이때 단순히 성능 수치 차이만 확인하는 것이 아니라, 모델별 성능 순위가 유지되는지, 성능 차이의 크기가 유사한지, 전체적인 성능 경향이 일관되게 나타나는지도 함께 검토한다.

3.4. 주요 기능의 구현

현재까지의 구현은 치과 파노라마 **X-ray**와 심전도 데이터를 대상으로, 태스크 설정, 라벨 설정, 평가 모델 구성, **feature** 추출, **proxy set** 생성, **real-proxy** 평가 비교의 흐름을 실험적으로 검증할 수 있도록 설계하였다. 본 연구의 목적은 새로운 의료 **AI** 모델 자체를 개발하는 것이 아니라, 이미 존재하거나 재현 가능한 여러 모델을 대상으로 원본 데이터 기반 평가와 **feature-level proxy** 평가가 얼마나 유사한 결론을 제공하는지 확인하는 데 있다.

치과 파노라마 **X-ray**의 경우, 평가 태스크는 이미지 단위 **multi-label classification**으로 설정하였다. 한 장의 파노라마 이미지에 대해 여러 치과 소견의 존재 여부를 동시에 예측하는 구조이며, 최종 라벨은 이미지 단위 판단 가능성, 라벨 명확성, 표본 수 확보 가능성, **backbone feature** 적합성을 기준으로 치아 우식, 치근단 병소, 잔존치근, 치주골 소실, 매복치 등으로 구성하였다.

심전도 데이터의 경우에는 **AF**, **1° AVB**, **RBBB**, **PVC**, **LBBB**의 5개 라벨을 중심으로 **multi-label classification task**를 설정하였다. 이 라벨들은 ECG 기반 진단 모델에서 자주 다루어지는 소견이며, 공개 모델이나 **foundation model**에 **5-class** 또는 **5-label classification head**를 붙여 실험할 수 있다. 특히 심전도 데이터는 이미지와 달리 **1D** 시계열 신호이므로, **CNN** 기반 **1D encoder**, **Transformer** 기반 **encoder**, **ECG foundation model** 등 다양한 구조의 **feature space**를 비교하기에 적합하다.

평가 모델은 프레임워크의 범용성을 확인하기 위해 서로 다른 **backbone** 구조를 포함하도록 구성한다. 치과 파노라마 **X-ray**에서는 **ResNet-50**, **DenseNet-121**,

EfficientNet-B0, ViT-Base를 평가 모델 후보로 설정하였다. ResNet-50은 표준 CNN baseline으로 사용할 수 있고, DenseNet-121은 feature reuse 구조를 통해 의료 영상의 미세한 특징을 잘 포착하는 모델로 활용할 수 있다. EfficientNet 계열은 비교적 효율적인 구조를 가진 모델로, ViT-Base는 CNN과 다른 attention 기반 feature space를 제공하기 때문에 proxy evaluation이 다양한 구조에서도 유효한지 확인하는 데 적합하다.

또한 단순히 서로 다른 모델 구조만 비교하는 것이 아니라, 같은 모델 안에서도 학습 정도가 다른 checkpoint를 활용하여 성능 스펙트럼을 구성한다. 예를 들어 under-fitted 모델, mid-trained 모델, fully-trained 모델을 구분하여 평가하면, proxy evaluation이 성능이 낮은 모델과 높은 모델을 실제 평가와 유사하게 구별할 수 있는지 확인할 수 있다. 치과 파노라마 실험에서 4개의 backbone과 모델당 3단계 성능 tier를 조합해 총 12개 모델을 테스트한다. 이 구조를 활용하면 real evaluation 성능을 X축, proxy evaluation 성능을 Y축으로 둔 산점도를 구성하여, 두 평가 결과가 대각선에 가깝게 정렬되는지 확인할 수 있다.

심전도 평가 모델은 공개적으로 활용 가능한 ECG 모델과 foundation model을 중심으로 HuBERT-ECG, ECGFounder, ECG-JEPA, ECG-FM으로 구성하였다. 일부 모델은 AF, PVC, LBBB, RBBB, 1° AVB를 포함한 다수의 ECG 조건을 이미 다루고 있으며, 일부 foundation model은 5개 라벨 분류를 위해 별도의 multi-label classification head를 붙여 fine-tuning하는 방식으로 활용할 수 있다.

구현 과정에서는 먼저 원본 데이터를 모델 입력 형태로 전처리한다. 치과 파노라마 X-ray는 이미지 크기 조정, 정규화, tensor 변환을 수행하고, ECG는 신호 길이 정규화, lead 구성 정리, sampling rate 통일 등의 전처리를 수행한다. 이후 각 모델에 원본 데이터를 입력하여 내부 real evaluation 결과를 산출한다. 이때 병원 내부 평가에서는 원본 데이터를 그대로 사용하되, 외부 평가 단계에서는 원본 데이터를 사용하지 않도록 실험 환경을 분리한다.

Feature 추출은 encoder와 classifier head를 분리하여 수행한다. 이미지 모델의 경우 classifier 직전 layer의 embedding을 feature vector로 저장하고, ECG 모델의 경우 1D CNN, Transformer, foundation model encoder가 출력하는 embedding을 저장한다. 각 샘플에 대해 feature vector, 정답 라벨, 예측 score, 필요 시 모델 ID와 데이터 출처 정보를 함께 기록한다. 이 feature는 이후 proxy set을 구성하는 기본 단위가 된다.

Proxy set은 정보 공유 수준에 따라 두 가지 방식으로 구성한다. 첫 번째는 sample-level feature를 익명화하여 사용하는 방식이다. 이 경우 원본 이미지는 공유되지 않지만, 모델이

실제 원본 데이터로부터 추출한 표현을 사용하므로 **real evaluation**과 가장 가까운 결과를 보일 가능성이 높다. 두 번째는 **class-wise mean, covariance, sample count**만을 이용해 **synthetic feature**를 생성하는 방식이다. 이 방식은 개별 **sample feature**를 공유하지 않아도 되므로 개인정보 보호 측면에서 더 안전하지만, 원본 **feature** 정보가 요약되는 과정에서 일부 정보 손실이 발생할 수 있다.

평가 결과는 **real evaluation**과 **proxy evaluation**의 정합성을 중심으로 분석한다. 각 모델에 대해 **real AUROC**와 **proxy AUROC**, **real AUPRC**와 **proxy AUPRC**를 비교하고, 두 값의 차이를 계산한다. 또한 모델별 성능 순위가 **real evaluation**과 **proxy evaluation**에서 동일하게 유지되는지 확인한다. 절대 성능값이 완전히 일치하는지보다, 평가 결과의 방향성과 모델 간 상대적 순위가 유지되는지가 핵심 판단 기준이 된다.

예상되는 결과는 다음과 같다. **Sample-level feature**를 사용하는 **proxy evaluation**은 내부 **real evaluation**과 가장 높은 일치도를 보일 가능성이 크다. **Class-wise statistics**만을 사용하는 방식은 정보 손실로 인해 성능 차이가 다소 커질 수 있지만, 모델 간 성능 순위가 유지된다면 더 강한 **privacy** 조건에서도 대체 평가가 가능하다는 근거를 제공할 수 있다. 또한 다양한 **backbone**와 성능 **tier**를 가진 모델들을 함께 평가함으로써, 제안한 프레임워크가 특정 모델에만 우연히 작동하는 것이 아니라 여러 구조와 성능 수준에서 일관되게 적용 가능한지 확인할 수 있다.

3.5. 기타

본 연구의 프레임워크는 원본 의료 데이터 반출이 어려운 환경에서 의료 AI 모델을 평가하기 위한 방법론적 접근이라는 점에서 의의가 있지만, 실제 적용을 위해서는 몇 가지 제약사항을 함께 고려해야 한다.

첫째, 태스크와 라벨 설정이 **proxy evaluation**의 신뢰성에 큰 영향을 미친다. 본 연구에서는 방법론 검증을 위해 비교적 라벨이 명확하고 이미지 또는 신호 단위로 판단 가능한 태스크를 우선 선정하였다. 그러나 실제 의료 환경에서는 질환의 중증도, 병변 위치, 복합 질환 여부처럼 라벨 경계가 모호한 경우가 많다. 이러한 태스크에서는 **feature-level proxy set**이 실제 평가 결과를 충분히 근사하지 못할 수 있다. 따라서 초기 실험에서는 치과 파노라마 X-ray의 존재/부재 기반 **multi-label classification**이나 ECG의 대표 부정맥·전도 이상 분류처럼 명확한 태스크를 중심으로 검증하고, 이후 더 복잡한 태스크로 확장하는 것이 적절하다.

둘째, **feature vector**의 개인정보 보호 수준에 대한 추가 검토가 필요하다. 본 연구에서는 원본 의료 데이터를 외부로 반출하지 않고 **feature vector** 또는 **class-wise statistics**만을 공유하지만, **feature vector** 역시 원본 데이터로부터 추출된 중간 표현이다. 따라서 특정 조건에서는 **feature inversion attack**이나 **membership inference attack**과 같은 방식으로 원본 정보 또는 개인의 포함 여부가 추론될 가능성을 완전히 배제할 수 없다. 실제 병원 환경에 적용하기 위해서는 **feature** 익명화, 차원 축소, **noise injection**, **differential privacy** 등의 보완 기법을 함께 적용해야 한다.

셋째, 모델 구조에 따라 **feature space**의 성질이 달라질 수 있다. CNN 기반 모델, DenseNet 계열, EfficientNet, Vision Transformer, ECG foundation model은 **feature**를 형성하는 방식이 서로 다르다. 따라서 특정 **backbone**에서는 **proxy evaluation**이 **real evaluation**을 잘 근사하더라도, 다른 구조에서는 근사 성능이 낮아질 수 있다. 이를 보완하기 위해 본 연구에서는 여러 **backbone**와 학습 수준이 다른 **checkpoint**를 함께 평가하여, **proxy evaluation**의 범용성과 한계를 동시에 확인해야 한다.

넷째, 데이터 규모와 클래스 불균형 문제도 중요한 제약사항이다. 특히 의료 데이터에서는 특정 질환의 양성 샘플 수가 부족한 경우가 많고, 일부 라벨은 중복 **positive** 형태로 나타날 수 있다. 치과 파노라마 라벨 설정에서도 **all-negative**, 단일 **positive**, 중복 **positive** 구성을 고려하고 있으며, 각 라벨별 양성 샘플 수 확보 가능성이 라벨 선정의 중요한 기준으로 제시되어 있다. 따라서 **proxy feature**의 분포를 안정적으로 구성하기 위해서는 라벨별 최소 표본 수와 클래스 불균형 보정 방법을 함께 검토해야 한다.